

「绳子戏法」 – 人工智能的数学


YKY [July 22, 2026]

最近经常讲政治，如果不进一点人工智能，大家可能觉得我是冒牌货了。今次进一种叫 string diagrams 的东西，它是我近来最有趣的发现，也跟我研究的突破密切有关。


事情开始于考虑逻辑的 **对称性结构**，例如 $\text{我爱你} \neq \text{你爱我}$ ，但 $\text{我爱你} \wedge \text{你爱我} = \text{你爱我} \wedge \text{我爱你}$ 。这是一种叫 **交换性** 的对称。而大家应该也听过，作为现代 LLM 最基本元件的 Transformer 也有这种交换对称性。于是就有令我很兴奋的猜测：会不会 Transformer 就暗藏逻辑的结构呢？但事与愿违，Transformer 结构跟逻辑结构 总是对不上。Transformer 将句子 拆成 tokens，例如「我」、「爱」、这样的一些原子概念，而 tokens 是可交换的。但 $\text{我爱你} \neq \text{你爱我}$ 是 **不可交换**。于是，单词 似乎不对应 tokens，但如果 句子/命题 对应一个 token，则它又可以分拆为更小的单位。总之，好像逻辑结构 对不上 Transformer 结构。

后来我开始研究 **对称性** 是怎样用 神经网络 实现（当然，其实只是其他人的研究成果，我在学习）。Kolmogorov-Arnold 给出了 对称函数的一般 **代数形式**： $f(x_1, \dots, x_n) = g(h(x_1) + h(x_2) + \dots)$ 。显然，**加法** 是有交换性的，而这个定理告诉我们，所有对称函数其实都可以用这种加法结构实现¹。但我直接用这种神经网络做逻辑推理，效果却不太理想。

于是又回到 Transformer。它也有对称性，但这种对称性是用 dot product 和某些 matrix 运算 巧妙地达成的（图 1 的左下角 就是著名的 Self-Attention 公式，亦即 Transformer 的结构），它不是根据什么定理。我了解这些运算 **为什么** 达成了对称性，而我直觉觉得 它可能跟 string diagrams 有关。

$$Z := \mathcal{O} \check{W} \otimes (\mathcal{O} \hat{W} \otimes X)$$
$$\alpha := \left(\mathcal{O} \frac{\langle Q, K \rangle}{\sqrt{d_k}} \right) V$$


于是我「自创」了某种 string diagram. 由于我很喜欢颜色（我弟弟是色盲），我用不同的颜色代表 $Q, K, V, \dots$ 这些变量（及其维数），企图「追踪」那些变量为什么在交换下不变：



大家应该记得，在线性代数里，一个 $m \times n$ 的矩阵 乘以 $n \times l$ 的矩阵，给出 $m \times l$ 的矩阵，夹在中间的 n 被 **消去** 了。作为特例， $(1 \times n) \times (n \times 1) = 1$ ，这就是两个矢量之间的 dot product。在我的图像里，夹在中间的绿色被消去了，但我错误地将绿色线画在外面，所以看不到这规律（我当时知道这规律，但我想不到它是可以图像化的，于是我的分析就停在了那里。）

后来我看到了 Abbott 2024 的论文，那瞬间才恍然大悟，原来我的图 (2) 跟他们的图 是一样的，也就是 图 (1) 的右下角。他们不需要用颜色，而是将两条线在空间上「夹着」的维度消去。而且这是对所有 tensor products 都适用的，那就是两个张量之间的 **缩并** (contraction)，也就是 TensorFlow 里面的 einsum（爱恩斯坦 求和约定）。²

这件事的意义是：代数上的对称性 可以用 string diagram 表示，而这些图可以根据一些特定的法则 做视觉上的 **变形** (string diagram rewriting)，保持 对称性的不变，而不需要写出 代数上的证明。那些法则就是 symmetric monoidal categories (SMCs) 的组合法则。

【岔开一点话题：如果大家懂一些 algebraic combinatorics，应该知道 **对称多项式** 有几种不同的 bases，例如 elementary (e), monomial (m), complete homogeneous (h), power sum (p), Schur (s), forgotten (f). 它们由 SMC 的生成元产生，而 **图重写** 对应于 多项式的 **基底变换**。暂时我还不清楚这个角度可以带来什么启发。】

这篇短文里我主要想讲的是：我一直在学习 范畴逻辑理论 里面很旧、很基本的一些东西，但最近我的「研究」终于接触到 别的研究者 的「前沿」，这感觉非常良好。（当然，这是指数学方面的研究，在 AGI 方面，我觉得我已经算是专家。）我想表达的是数学的神秘与奇妙，而这种「魔法」是有严谨的基础的，不是随意瞎扯出来的。

Abbott, Vincent (2024). *Neural Circuit Diagrams: Robust Diagrams for the Communication, Implementation, and Analysis of Deep Learning Architectures*. arXiv: 2402.05424 [cs.LG]. URL: <https://arxiv.org/abs/2402.05424>.

¹这个定理的证明其实颇为复杂，我看了两个截然不同的证明，都勉强看懂了，但完全想不出他们是怎样想出那些证明的。可以参看 DeepSet 和 PointNet 的论文。

²在图 (1) 的右边，会看到有些 $\rightarrow$ 的终点没有任何东西，好像有些讯息消失了，其实这就是 tensor contraction，而讯息没有消失，可以看成是保留了在两条绳之间的空白部分。